세 지역 자료 EDA | 검토 결과와 사용 안내

대상: 방문자·거주인구·관광체류강도. 모델 연결 후보 지역 변수 8개.

원자료: 방문자 688행 / 거주인구 14,145행 / 관광체류강도 765행(부산 전체 포함).

최종 변수: 방문자 592행 / 거주인구 7,790행 / 관광체류강도 592행.

거주인구는 예측기준월+행정동, 방문자·관광은 예측기준월+구군으로 연결한다.

모든 변수는 전월 관측자료 사용. 실제 공표일·사후 개정은 반영하지 않았다.

학습 분석: 기준월 202301~202508, 4,049,217개 점포·월. 시험 연결: 202602, 123,394개 점포.

202508 학습 정답의 확인 범위는 2026년 1월까지. 시험 정답은 2026년 2~7월.

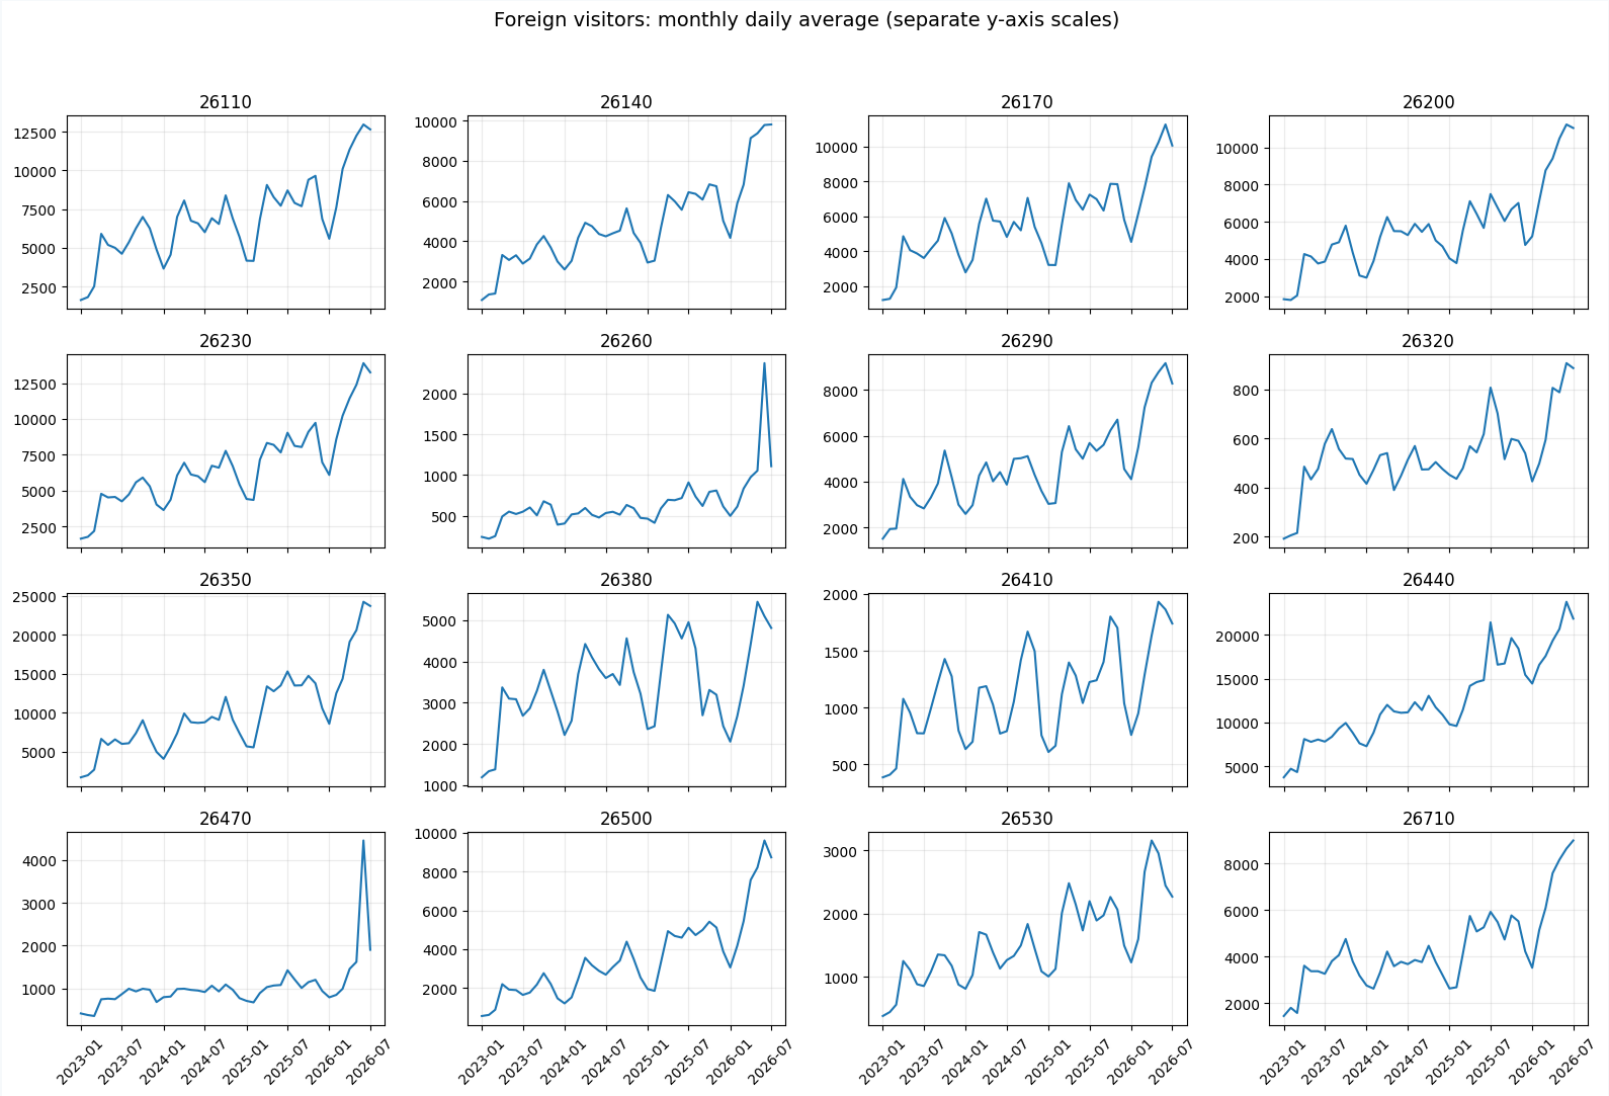
202301 방문자·관광 결측 126,130행(3.11%)은 202212 관측자료 부재 때문이다.

범위 검사 위반·무한대 0건. 기존 점포 행·정답을 유지하며 변수 연결을 검수했다.

이 문서는 지역 지표 EDA이다. 카드·통신 등 전체 모델 지표의 검토 완료를 뜻하지 않는다.

출처: 제공된 Colab 노트북 2개와 EDA_최종정리_작업자료.zip. 외부 사실을 새로 확인하지 않았다.

01 | 외국인 방문자: 구군별 관측월 추이



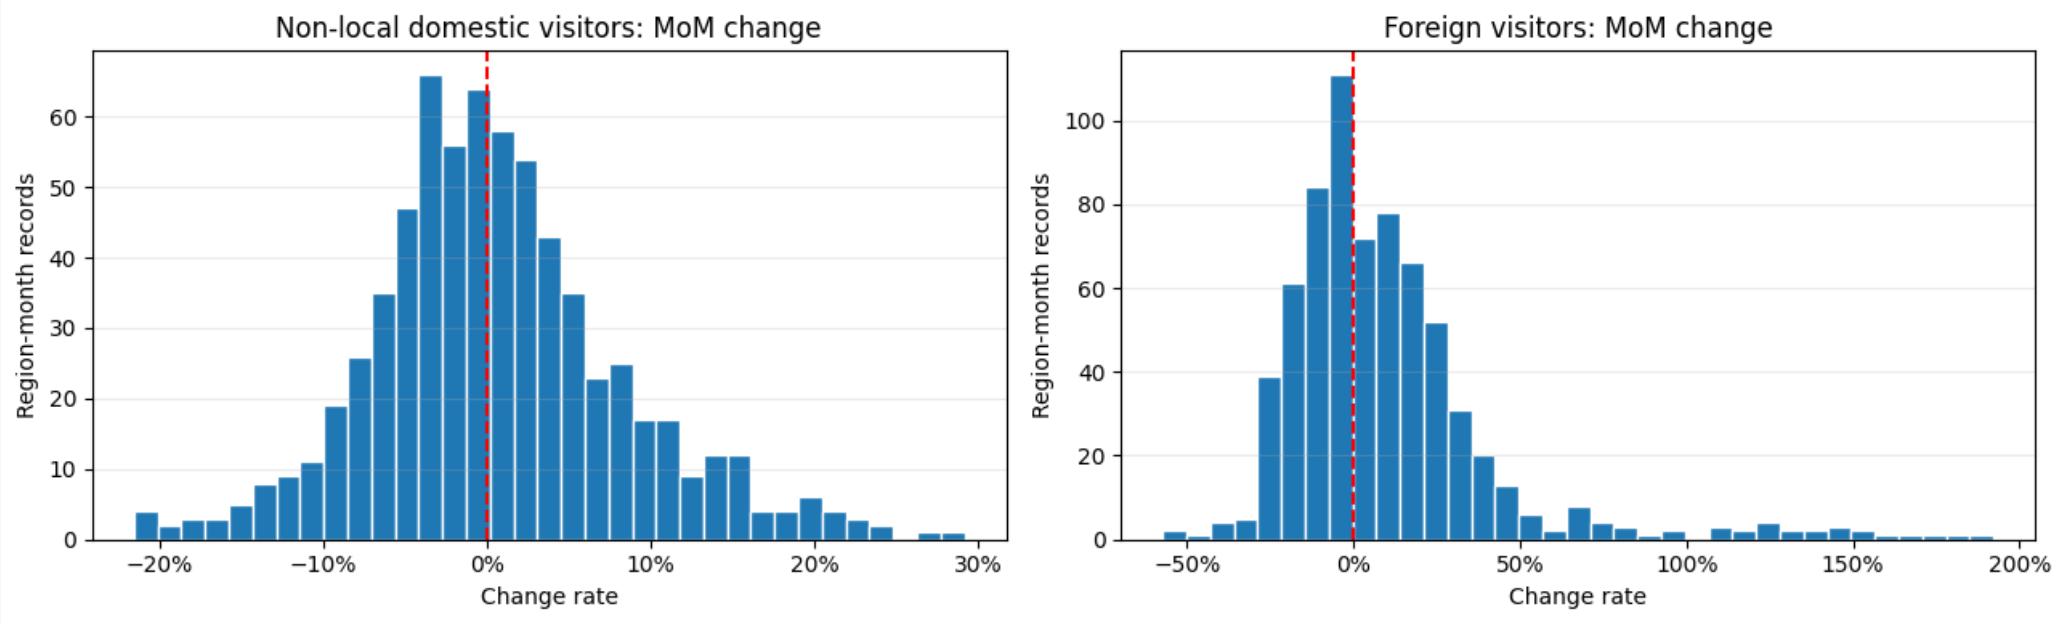
원자료 202301~202607. 구군마다 세로축 범위가 다르므로 선의 높이를 구군 간 직접 비교하지 않는다.
자료 말미의 급증·급감도 원자료 탐색에 포함됐다. 학습 분석의 입력 기간과는 구분한다.

02 | 외지인 방문자: 구군별 관측월 추이



외지인은 국내 외지인 방문자다. 값은 월별 일평균이며 월 전체 고유 방문자 수가 아니다.
금정구·남구의 반복 변동 등이 관찰되지만 행사·학사일정 등 원인은 확인하지 않았다.

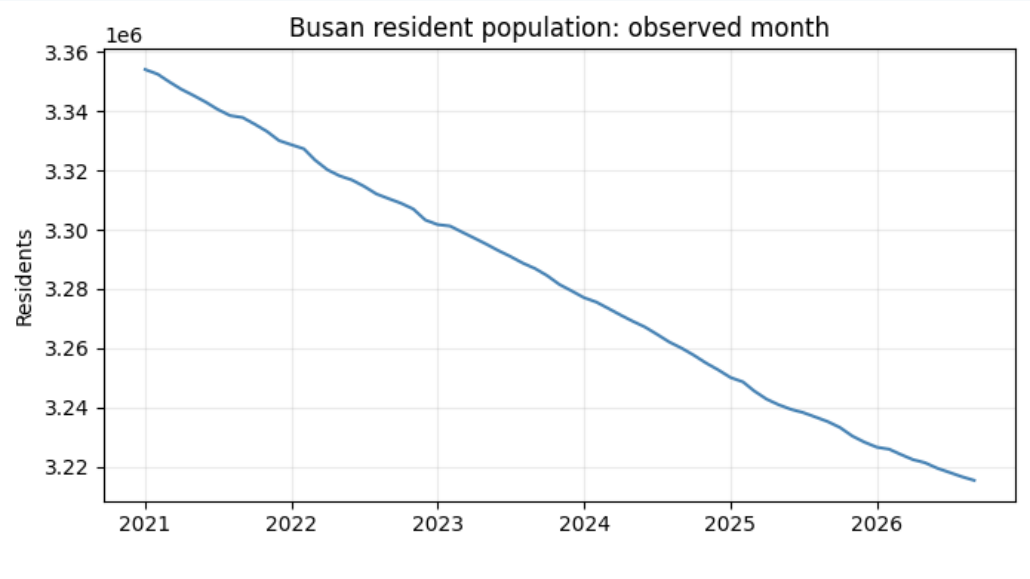
03 | 방문자 전월 변화율: 분포 비교



왼쪽은 외지인, 오른쪽은 외국인. 외국인 변화율의 양의 꼬리가 더 길게 나타난다.
변화율 0.1은 10%. 재계산 가능한 구간은 검산 일치했으며 초기 과거자료 부족 구간은 검산 한계가 있다.

노트북에 저장된 그래프 출력 / 새로운 모델 학습·성능 평가는 수행하지 않음

04 | 거주인구: 원자료 추이와 최종 변수 분포





원자료는 205개 행정동의 거주자 인구수이며, 방문자·체류인구와 다른 개념이다.

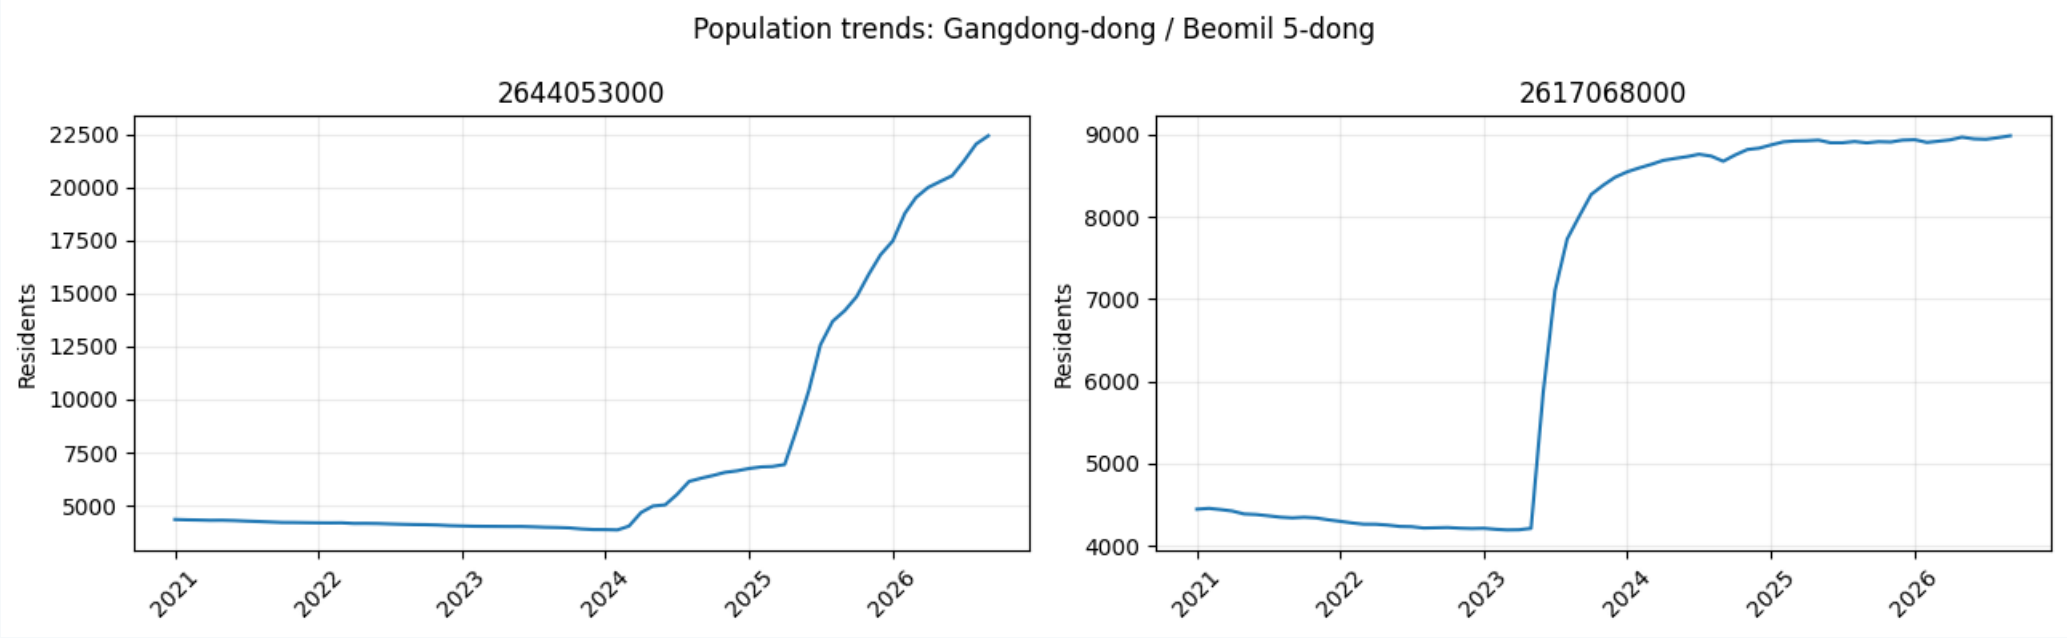
resident_yoy = 전월 인구 / 전년도 같은 관측월 인구 - 1. 100% 초과도 가능하다.

초기 노트북의 8,200행 분포 대신 최종 CSV 7,790행으로 오른쪽 분포를 재작성했다.

신호동 인구는 녹산동에 포함됐다는 담당자 확인을 적용했으며 독립적으로 재검증하지 않았다.

왼쪽: 원자료 관측월 / 오른쪽: 최종 전달 CSV의 예측기준월 202301~202602

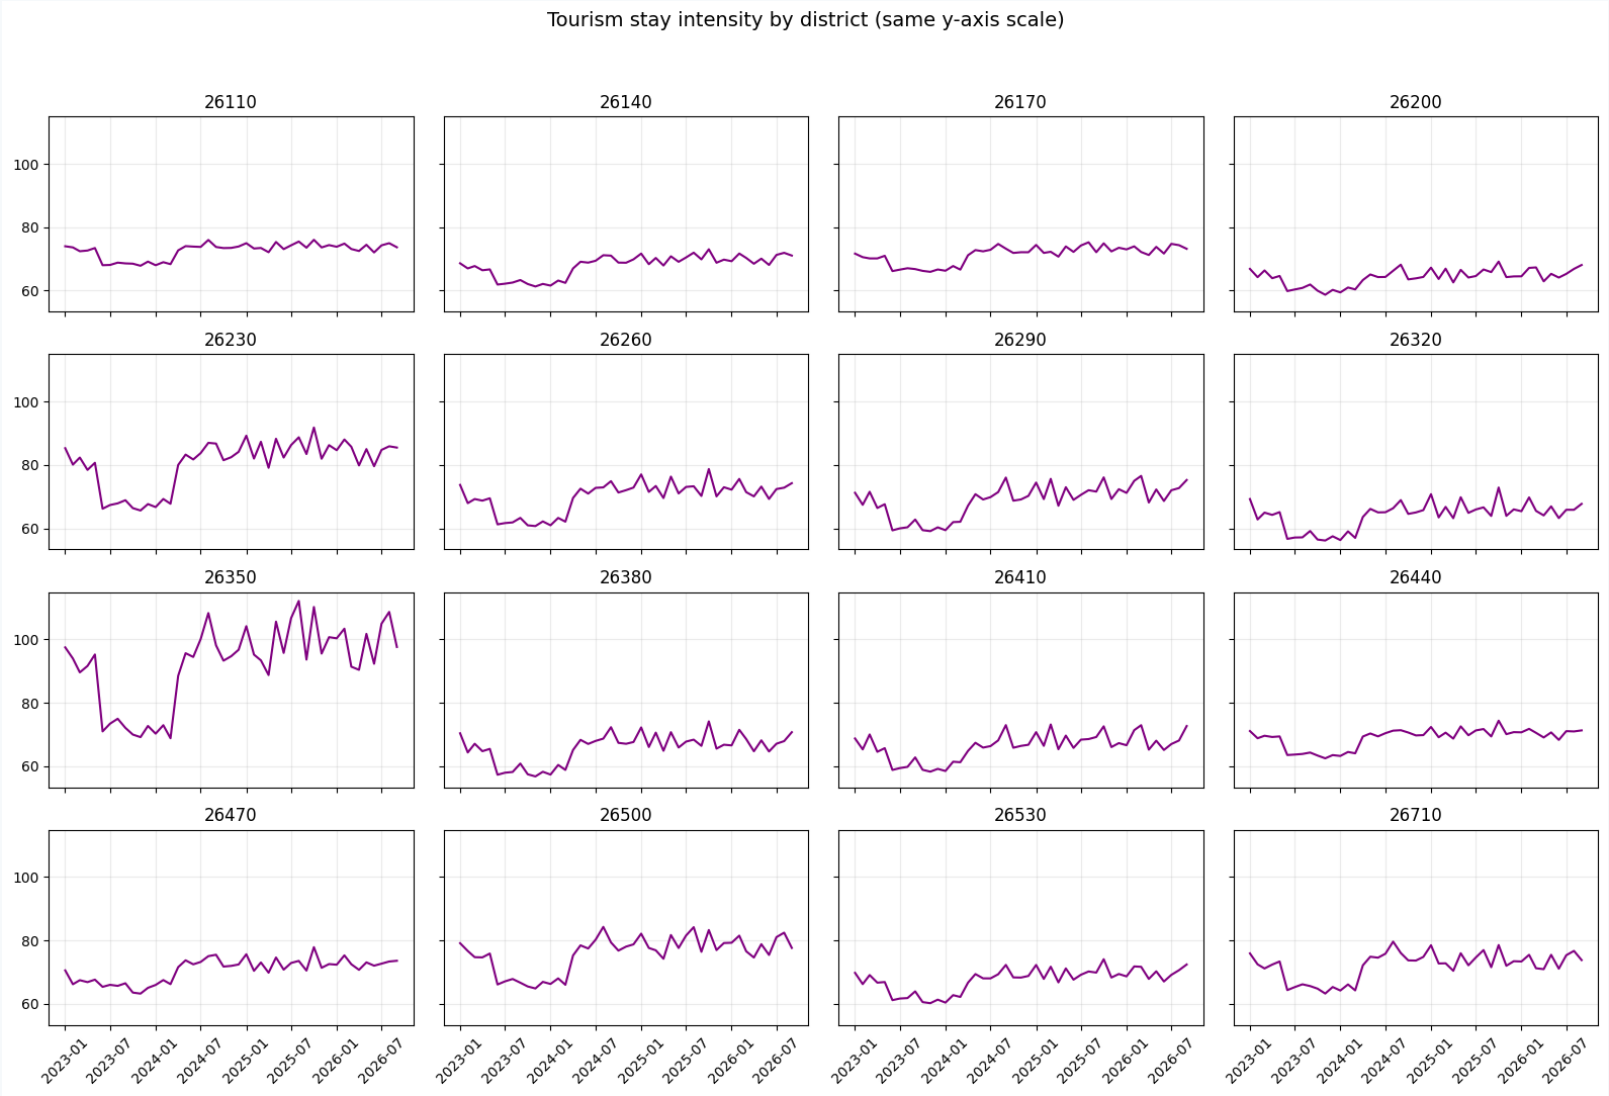
05 | 인구 변화가 큰 동: 원자료 추가 확인



왼쪽 강동동, 오른쪽 범일제5동. 여러 달에 걸친 인구 증가가 관찰된다.
증가 원인은 미확인. 큰 변화율을 임의로 삭제하거나 평균으로 대체하지 않았다.

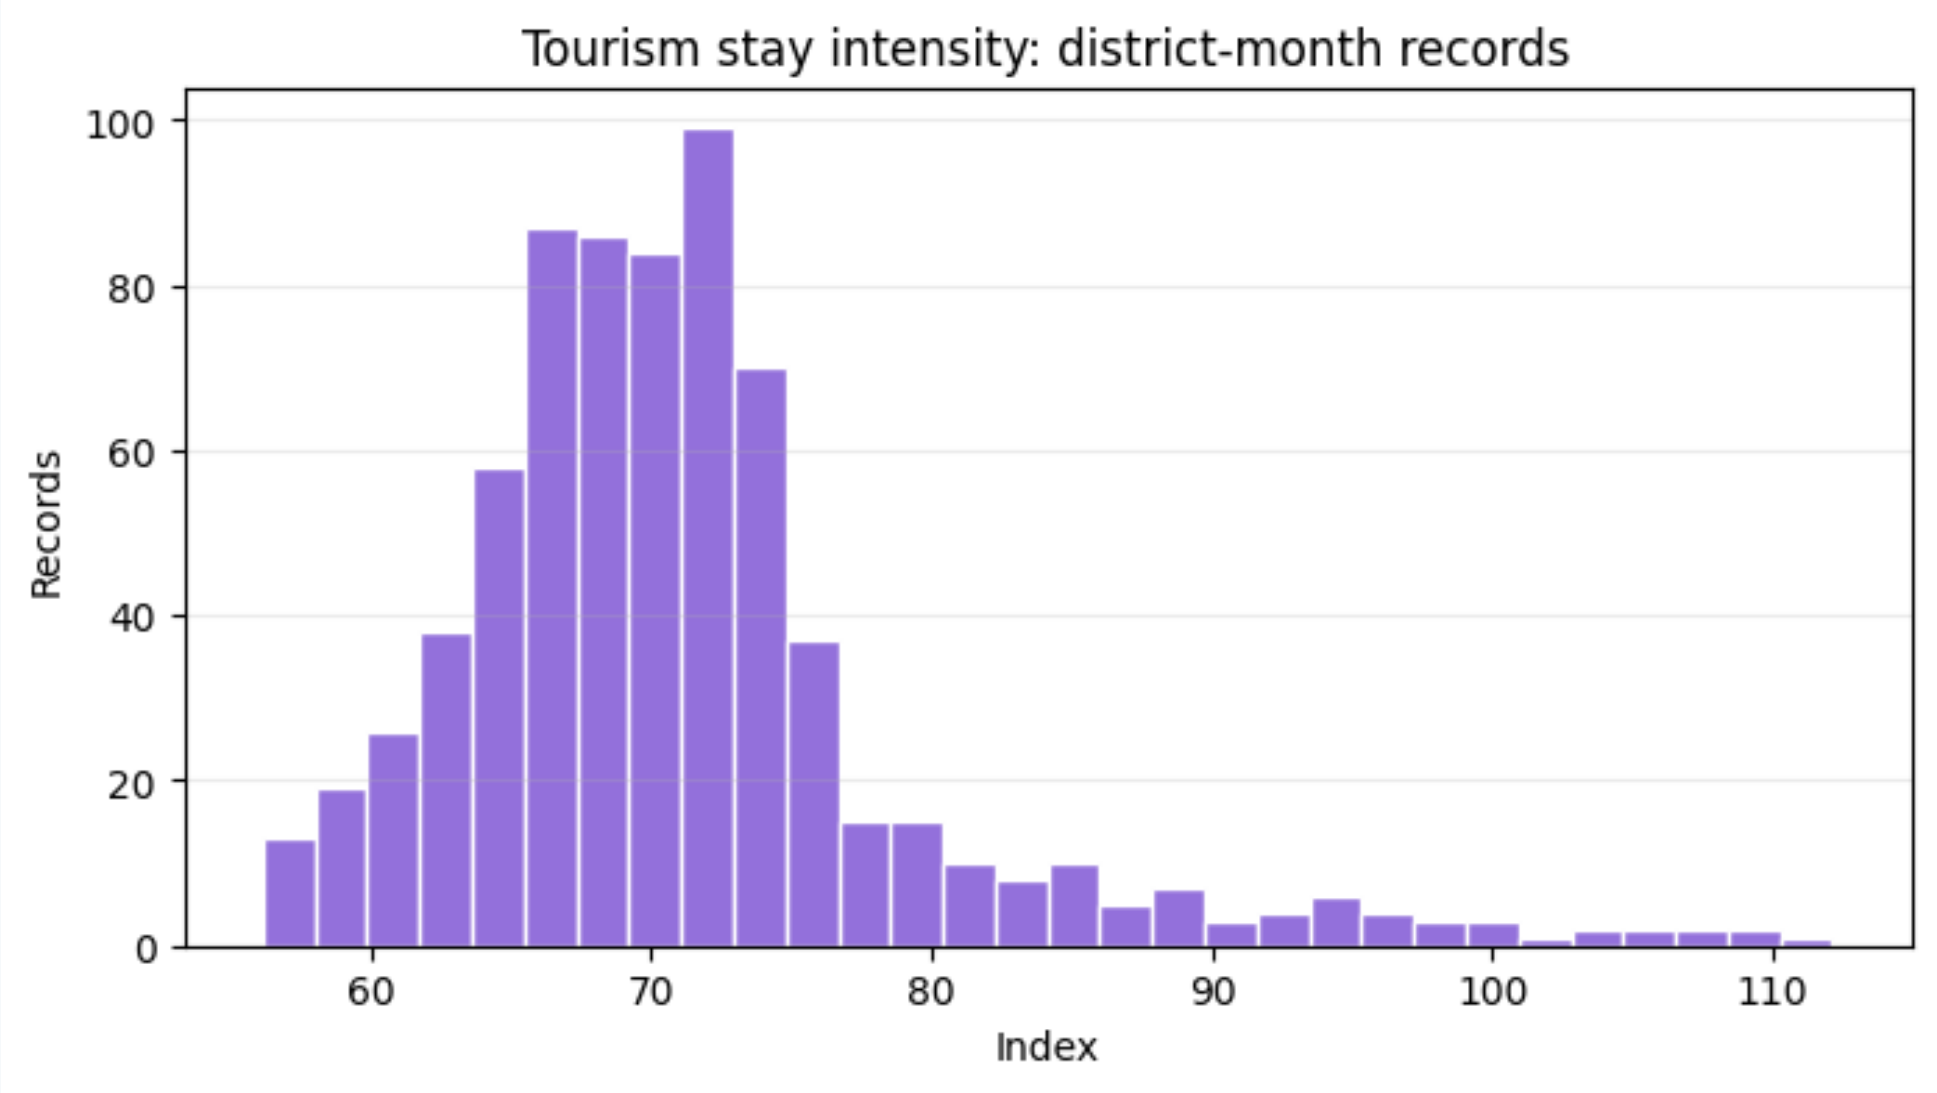
노트북에 저장된 그래프 출력 / 새로운 모델 학습·성능 평가는 수행하지 않음

06 | 관광체류강도: 구군별 관측월 추이



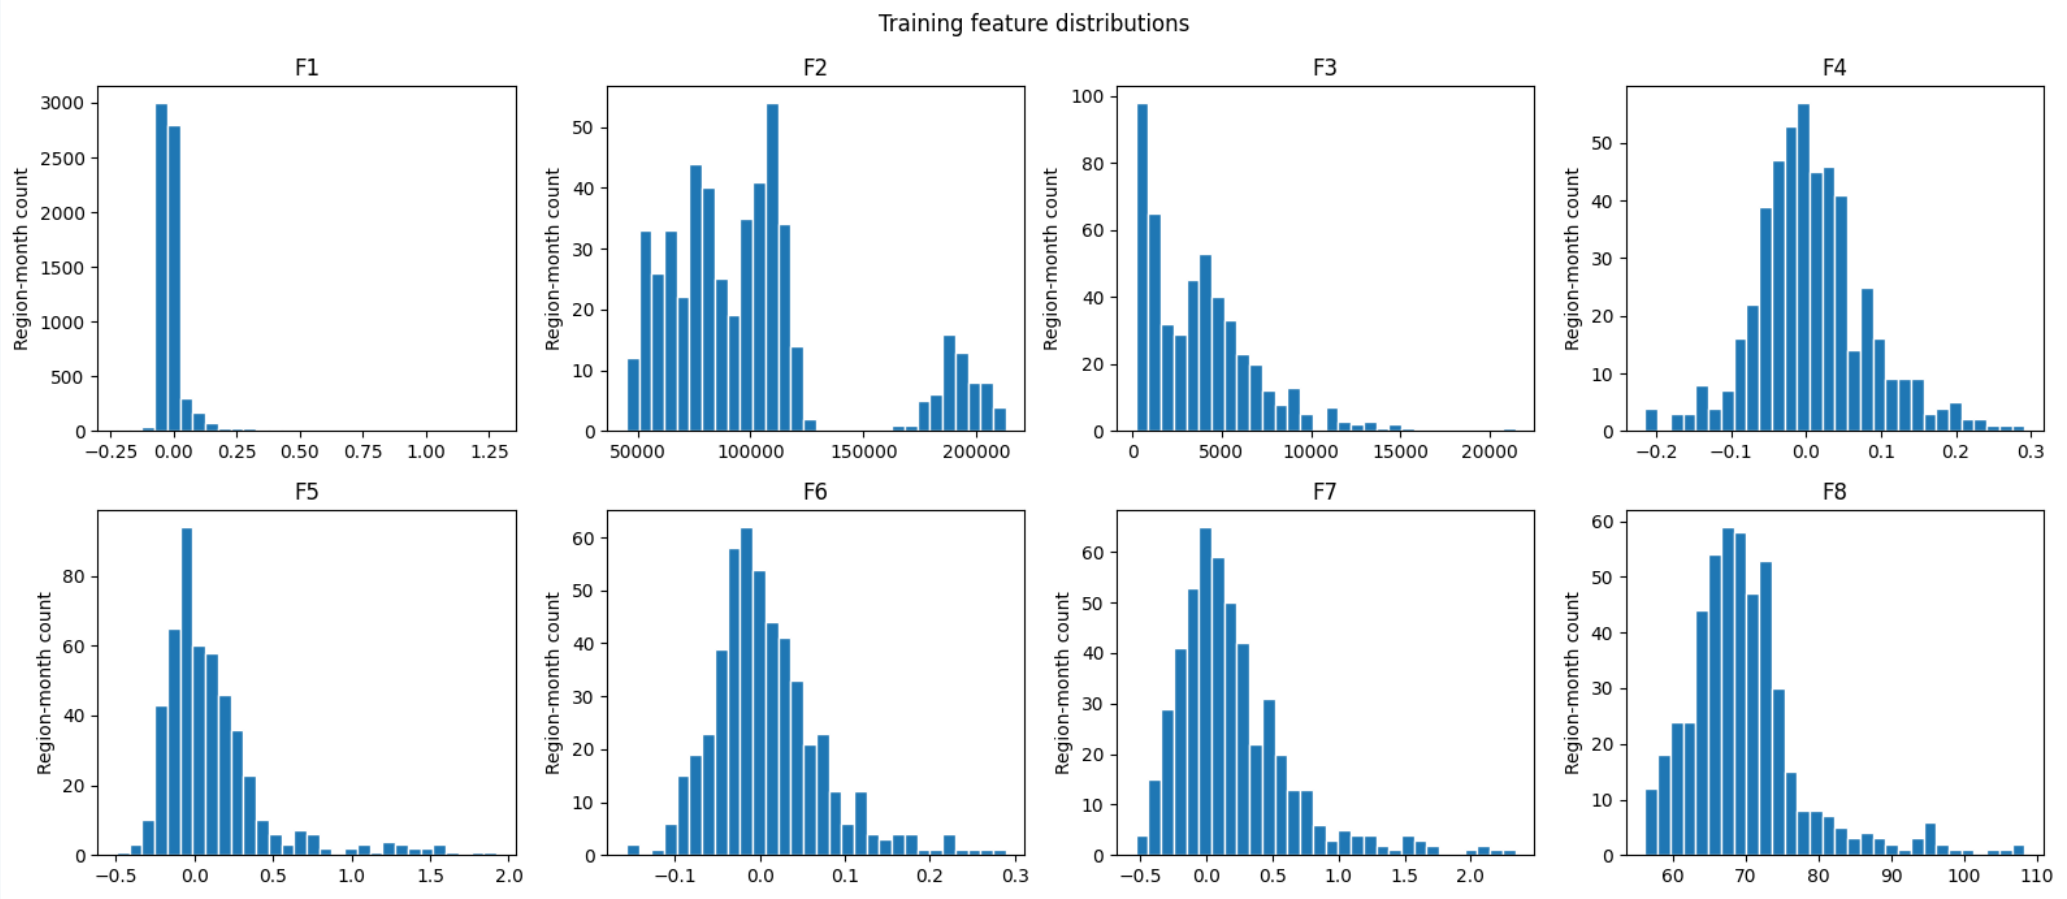
원자료 202301~202609. 종합지표 코드 21을 사용하며 모든 구군의 세로축은 같다.
관광체류강도는 지수다. 100 초과를 오류로 보거나 100%·방문자 수로 해석하지 않는다.

07 | 관광체류강도: 전체 구군·월 분포



부산 전체 45행을 제외한 16개 구군×45개월, 720행의 분포다.
해운대구의 높은 값 등이 관찰되지만 지수 산정 방식 변경 여부와 공통 변동의 원인은 미확인이다.

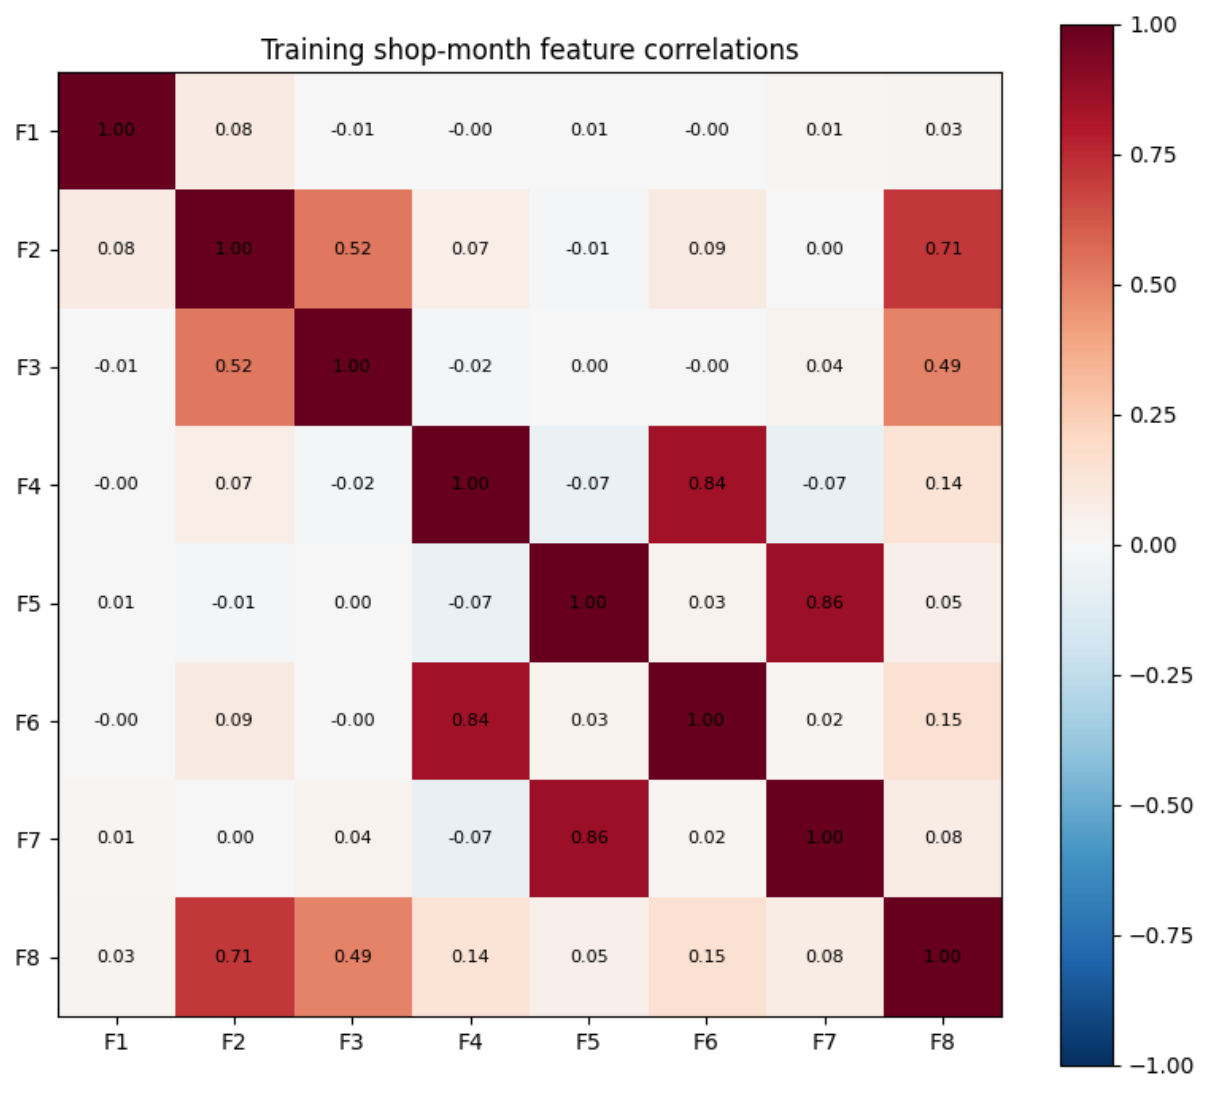
08 | 점포 연결 후 지역 변수 분포



F1 인구변화율 / F2 외지인수 / F3 외국인수 / F4·F5 각 전월 변화율 / F6·F7 각 3개월 평균 대비 / F8 관광지수.
학습 기간의 지역·월별 중복을 제거한 분포다. 점포·월 가중 기초통계와 집계 단위가 다르다.

노트북에 저장된 그래프 출력 / 새로운 모델 학습·성능 평가는 수행하지 않음

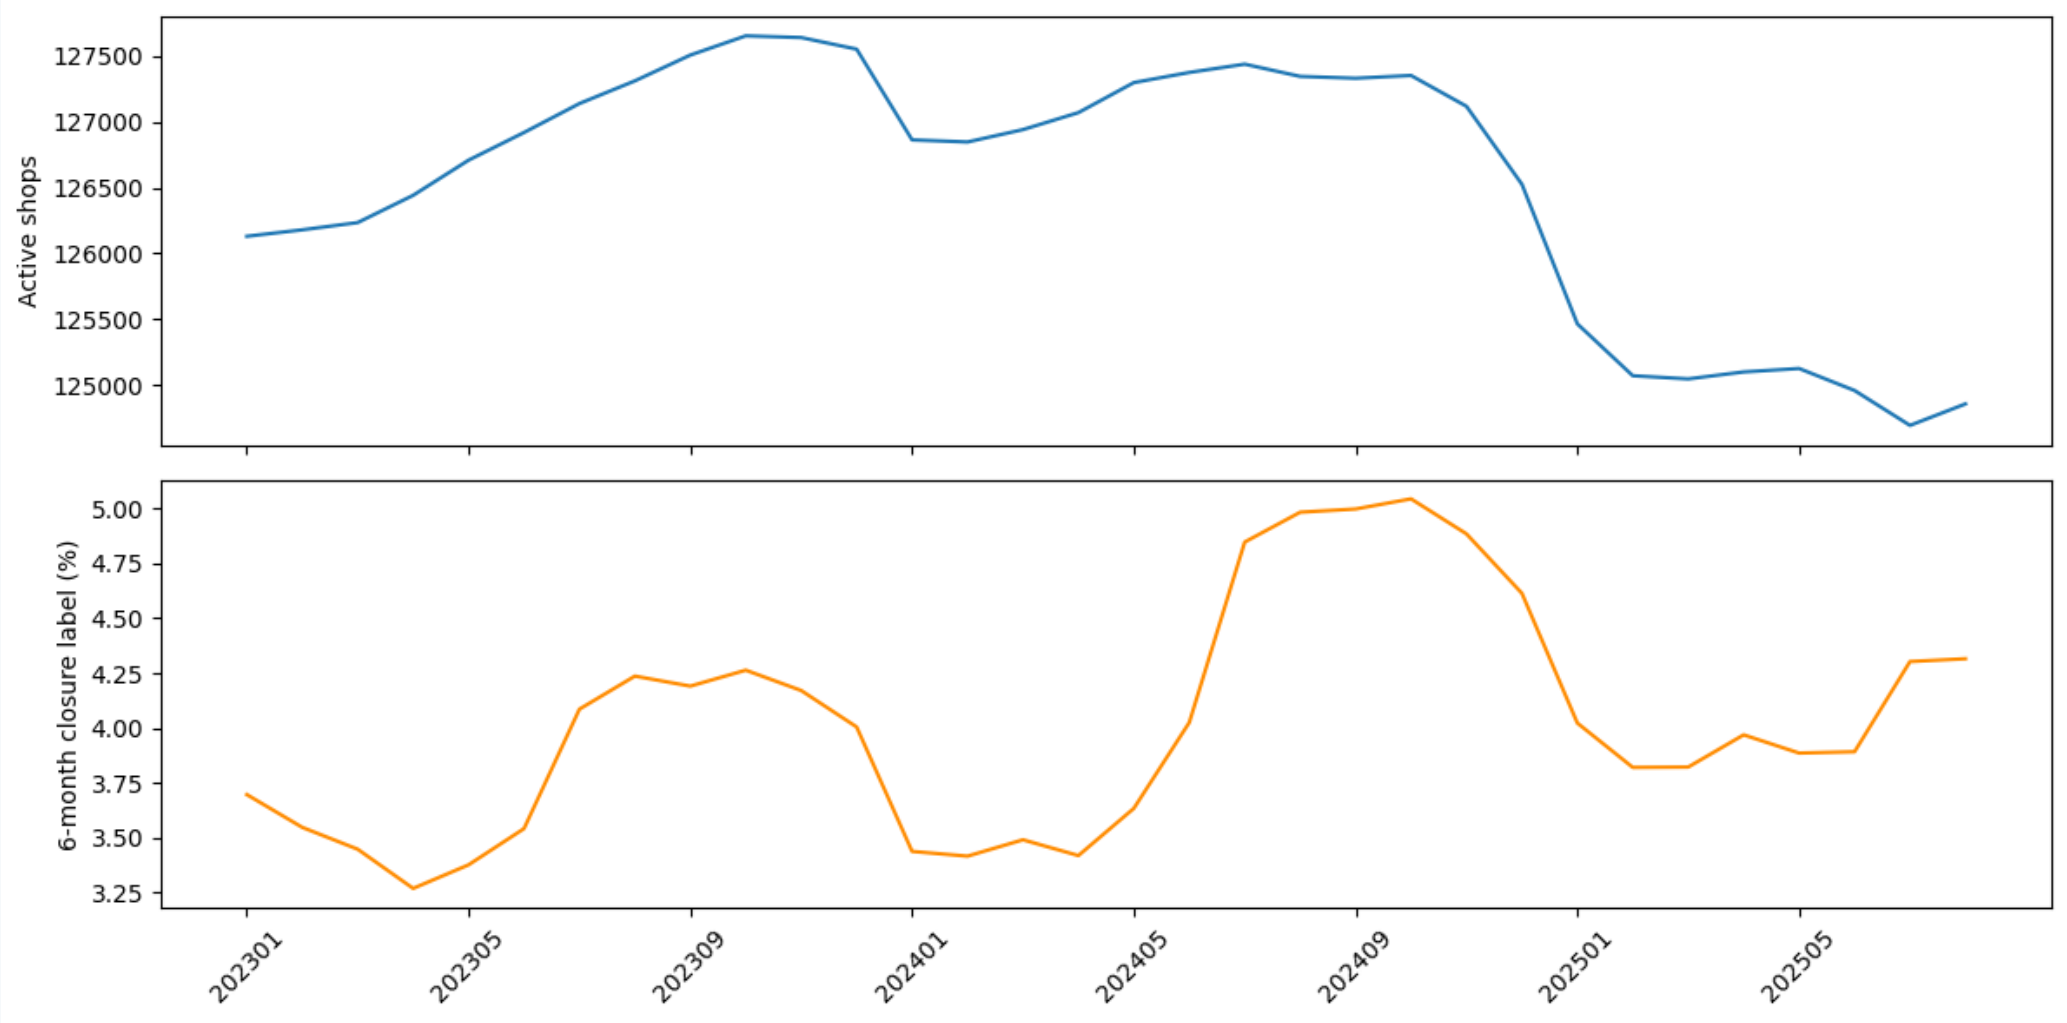
09 | 점포 연결 후 지표 간 상관



외지인 F4-F6: 0.838 / 외국인 F5-F7: 0.858. 절댓값 0.8 초과 쌍을 표시했으며 자동 삭제하지 않았다.
점포·월 기준 상관이므로 점포가 많은 지역에 가중된다. 폐업 예측력·인과관계·독립 표본의 유의성 검정이 아니다.

노트북에 저장된 그래프 출력 / 새로운 모델 학습·성능 평가는 수행하지 않음

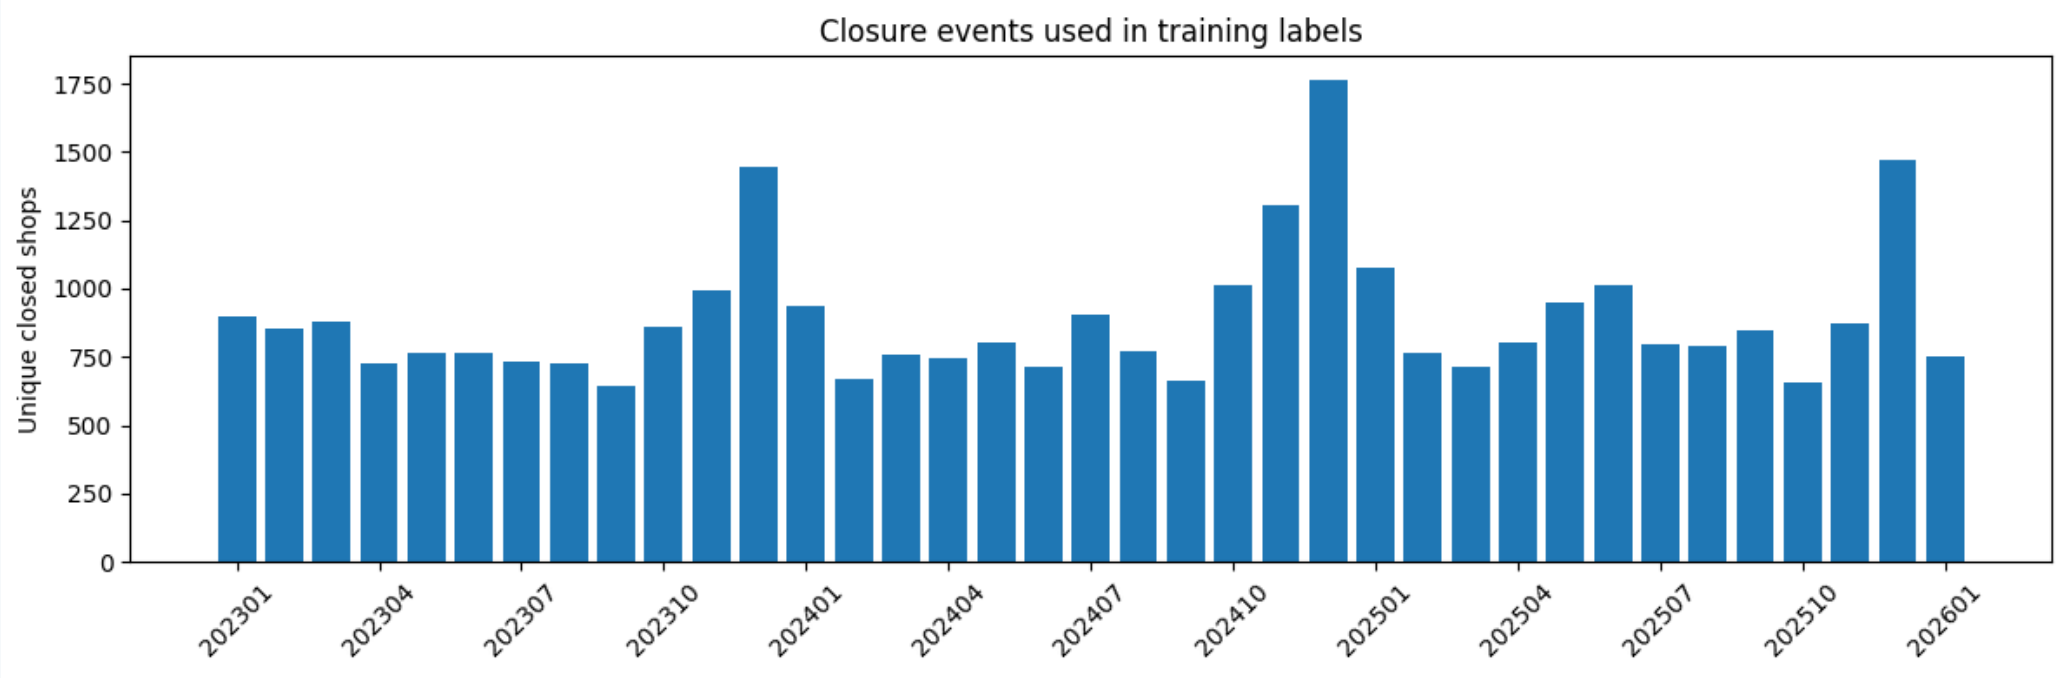
10 | 기준월별 점포 수와 6개월 폐업 정답 비율



학습 기준월 202301~202508. 아래 선은 해당 월의 실제 폐업률이 아니라 이후 6개월의 정답 비율이다.
정답 구간이 겹치므로 같은 폐업 사건이 여러 기준월에 반영된다. 상승만으로 일괄 폐업을 확정하지 않는다.

노트북에 저장된 그래프 출력 / 새로운 모델 학습·성능 평가는 수행하지 않음

11 | 실제 폐업월: 고유 점포 단위 집중 점검



학습 정답에 포함된 고유 폐업 점포 32,826개를 점포별 한 번씩 집계했다. 전체 폐업 모집단 통계는 아니다.
연말 기록 집중, 2025-05-30의 208개(해당 월 22.0%) 등을 기록했다. 실제 폐업 집중·일괄 행정처리 여부는 미확인이다.

노트북에 저장된 그래프 출력 / 새로운 모델 학습·성능 평가는 수행하지 않음

12 | 업종별 비교 확인 및 팀 전달사항

추가 확인: 최신 노트북에 업종별 비교 코드와 실행 결과가 저장돼 있다.

기준월 이전 최근 인허가의 업종으로 분류. 같은 최근 날짜에 여러 업종이면 별도 보류 집단으로 유지.

32개월 모두 업종 대응 없음 0건. 동일일 복수업종 보류는 월별 597~691개 점포.

92개 결과 집단, 합계 4,049,217개 점포·월이 출력돼 있다. 최종 모델 대표업종 정책의 확정과는 다르다.

출력 예: 일반음식점 3.88%, 휴게음식점 6.52%, 건강기능식품일반판매업 13.77%.

위 비율은 반복된 학습 점포·월의 6개월 정답 비율이다. 업종 고유 점포의 연간 폐업률로 해석하지 않는다.

전체 업종 92개 집단 CSV는 제공 ZIP에 없고 노트북에는 상위 20개만 출력돼 있다. 전체 표 전달은 보완 필요.

구별 출력 예: 해운대구 5.38%, 영도구 2.63%. 업종·규모·시기 구성과 원자료 처리 기준의 영향이 있다.

팀원 카드·통신·부동산 통합표에 연결할 때는 기준월의 의미가 예측기준월과 같은지 확인해야 한다.

파일은 빈값을 유지하고 지역 코드를 문자열로 읽는다. 통합 CSV 신규 연결은 이번 PDF 제작에 포함하지 않았다.